

DOCUMENTO DE ENTREGA: ANALÍTICA DE DATOS

Evidencia: AA2-EV03. Video configuración de analítica de datos

Aprendiz: Diego Alejandro Arboleda Cuero

Instructor: Luis Fernando Alzate Manotas

Programa: Aplicación de la Inteligencia Artificial en la Integración de Datos

Código de Programa: 21720207

Centro de Formación: Servicio Nacional de Aprendizaje (SENA)

17 de septiembre de 2026

Ficha Técnica del Proceso Formativo

- **Competencia:** 220501115 - Integrar datos según procedimiento técnico y especificaciones de proceso de negocio.
 - **Resultado de Aprendizaje:** 220501115-02 - Procesar datos implementando herramientas de inteligencia artificial generativa, procedimiento técnico y metodología estadística.
 - **Herramienta Analítica:** Orange Data Mining.
 - **Dataset Procesado:** WineQT.csv (1,143 muestras de laboratorio).
-

1. Acceso al Video Demostrativo

El video explicativo en el que se demuestra el flujo de trabajo en Orange Data Mining, abarcando la ingesta, normalización, reducción de dimensionalidad con PCA, filtrado por relevancia y evaluación ANOVA, se encuentra disponible en el siguiente enlace público:

Enlace Google Drive:

<https://drive.google.com/file/d/1CDSqDPxZyhe2cLfHbMCdaqbb3r8aRaPq/view?usp=sharing>

2. Resumen Técnico del Ejercicio Realizado

2.1. Justificación de la Herramienta

Se seleccionó **Orange Data Mining** por su entorno visual basado en flujos de trabajo (*workflows*), lo que permite integrar la preparación de datos, la selección de atributos y algoritmos de reducción de dimensión de manera ágil y libre de código.

2.2. Ingesta y Preprocesamiento de Datos

A través del nodo **CSV File Import** se cargaron 1,143 registros con 11 variables químico-físicas. Mediante el widget **Select Columns** se descartó la variable **Id** (enviada a *Ignored*) para prevenir distorsiones analíticas, definiendo **quality** como variable objetivo (*Target*). En el widget **Preprocess** se aplicó la normalización al intervalo $[0, 1]$, nivelando las escalas de atributos con rangos dispares (como la densidad $\approx 0,99$ frente al dióxido de azufre total > 200).

2.3. Reducción de Dimensionalidad (PCA)

Se implementó el algoritmo de **Análisis de Componentes Principales (PCA)** sobre los datos normalizados, reduciendo el espacio de 11 dimensiones a 2 componentes principales (PC_1 y PC_2). Esta proyección conserva el **45.8 % de la varianza total** (PC_1 : 28,7 %, PC_2 : 17,1 %). Al desplegar el **Scatter Plot** coloreado por la variable objetivo **quality**, se evidencia que PC_1 separa adecuadamente los vinos de baja calidad (tonos cian/azul a la izquierda) de los de alta calidad (tonos amarillos a la derecha).

2.4. Análisis Estadístico y Selección de Atributos

- **Correlations:** El análisis de Pearson confirmó que el ácido cítrico presenta una correlación negativa significativa con el pH ($-0,546$) y la acidez volátil ($-0,544$).
- **Rank:** Mediante regresión univariada y el método *RReliefF*, se identificaron los 5 atributos con mayor capacidad discriminativa: **alcohol**, **volatile acidity**, **sulphates**, **citric acid** y **total sulfur dioxide**.
- **Edit Domain y Box Plot:** Para habilitar la comparación por categorías, la variable **quality** fue transformada a tipo categórico mediante **Edit Domain**. Los diagramas de caja por subgrupos y la prueba de análisis de varianza **ANOVA** ($p < 0,001$) confirmaron que los vinos de máxima calidad (8.0) promedian 11,93 % de alcohol frente a un 9,69 % en calidades inferiores (3.0), registrando a su vez una caída drástica en la acidez volátil (de 0,897 a 0,41).

2.5. Conclusión

El pipeline analítico desarrollado demuestra estadísticamente que la calidad del vino tinto está determinada principalmente por un mayor volumen de alcohol combinado con una baja presencia de acidez volátil, validando el uso de herramientas analíticas por nodos para el diagnóstico industrial y la toma de decisiones.